

Adattudomány MSc – záróvizsga tételek

Bence Dáné

2026

Tartalomjegyzék

1. Az adattudomány elméleti háttéréhez kapcsolódó alapismeretek.	1
1.1. 1. tétel: információbiztonsági alapok	1
1.2.	5
1.3. Gépi tanulási alapismeretek	6
2. Az adattudomány gyakorlati háttéréhez kapcsolódó alapismeretek.	10

1. Az adattudomány elméleti háttéréhez kapcsolódó alapismeretek.

1.1. 1. tétel: információbiztonsági alapok

Az információbiztonság alapfogalmai (CIA-hármas); a kiberbiztonság eszközei és céljai; kártékony programok, támadási technológiák; hozzáférés-szabályozás (DAC, MAC, RBAC, ABAC, CBAC); hozzáférés-szabályozás elosztott rendszerekben.

Információbiztonsági alapfogalmak

Az információbiztonság célja az információ és az információs rendszerek védelme a jogosulatlan hozzáféréssel, módosítással, megsemmisítéssel, szolgáltatás-kieséssel és visszaéléssel szemben. A klasszikus alapmodell a **CIA-hármas**:

- **Confidentiality – bizalmasság:** az információ csak jogosult személy, folyamat vagy rendszer számára legyen hozzáférhető. Példa: titkosítás, hozzáférés-vezérlés, jogosultságkezelés.
- **Integrity – sértetlenség:** az adat pontos, teljes és jogosulatlanul nem módosított. Példa: hash, MAC, digitális aláírás, tranzakciós naplózás.
- **Availability – rendelkezésre állás:** a jogosult felhasználók a szükséges időben elérik a rendszert vagy szolgáltatást. Példa: redundancia, mentés, terheléselosztás, DoS-védelem.

Ezeket gyakran kiegészítik további biztonsági célokkal: **hitelesség, elszámoltathatóság, nyomonkövethetőség és letagadhatatlanság**. A hitelesség azt jelenti, hogy a forrás vagy entitás valóban az, akinek állítja magát; az elszámoltathatóság és nyomonkövethetőség pedig azt, hogy utólag rekonstruálható, ki mit tett.

A kiberbiztonság céljai és eszközei

A kiberbiztonság az információs rendszerek, hálózatok, alkalmazások, hardverek, adatok és szolgáltatások védelmét jelenti. A védelem nem csak technológia: emberek, folyamatok és szervezeti szabályok együttese.

Fő célja a szervezet működésének, adatainak és szolgáltatásainak védelme úgy, hogy a kockázatok elfogadható szintre csökkenjenek. Ez nem azt jelenti, hogy minden támadás teljesen kizárható, hanem azt, hogy a támadási felületet csökkentjük, a hibákat időben felismerjük, és incidens esetén gyorsan helyreállítunk. Ennek eszközei a megelőző kontrollok (például erős hitelesítés, titkosítás, jogosultságkezelés), a detektív kontrollok (naplózás, monitorozás, IDS/IPS), valamint a korrektív kontrollok (mentés, incidenskezelés, helyreállítás). A gyakorlatban rétegzett védelemre van szükség, mert egyetlen eszköz hibája esetén a többi kontrollnak kell csökkentenie a kárt.

Terület	Tipikus eszközök és célok
Rendszerbiztonság	Operációs rendszer jogosultságai, folyamat- és memóriavédelem, virtualizáció, izoláció, Trusted Execution Environment.
Kriptográfia	Titkosítás, hash, MAC, digitális aláírás, kulcskezelés, tanúsítványok.
AAA	Hitelesítés, feljogosítás, naplózás/elszámoltathatóság.
Hálózatbiztonság	Tűzfal, IDS/IPS, VPN, DMZ, szegmentáció, biztonságos protokollok.
Hardverbiztonság	Root of trust, TPM/HSM, biztonságos kulcstárolás, valódi véletlenszám-generátor, PUF.
Szoftverbiztonság	Secure SDLC, threat modeling, secure coding, review, tesztelés, dependency management.
Emberi és szervezeti védelem	Usable security, képzés, szabályzatok, kockázatmenedzsment, GDPR, NIS2.

Kártékony programok és támadási technológiák

Kártékony program minden olyan szoftver, amelyet a támadó jogosulatlan hozzáférés, adatlopás, károkozás, rejtőzködés vagy zsarolás céljából használ.

A kártékony programok gyakran nem önmagukban, hanem egy támadási lánc részeként jelennek meg: bejutás után perzisztenciát építenek ki, jogosultságot növelnek, oldalirányban mozognak a hálózatban, majd adatot lopnak, rombolnak vagy zsarolnak. A modern támadások sokszor technikai és emberi elemeket kombinálnak,

például phishinggel szerzik meg a belépési pontot, majd sérülékenység-kihasználással terjeszkednek tovább. Védekezésben fontos a naprakész patch-elés, a végpontvédelem, a jogosultságok minimalizálása, a hálózati szegmentáció, a biztonsági mentés és a felhasználók képzése. A ransomware elleni védelemben különösen lényeges az offline vagy elkülönített mentés, mert a támadó gyakran a mentéseket is megpróbálja törölni vagy titkosítani.

- **Vírus:** gazdaprogramhoz kapcsolódik, annak futásával terjed.
- **Féreg:** önállóan, hálózaton keresztül terjedhet.
- **Trójai:** hasznos programnak álcázza magát, de rejtett káros funkciót tartalmaz.
- **Ransomware:** titkosítja vagy zárolja az adatokat, majd váltságdíjat követel.
- **Spyware/keylogger:** információt, jelszót, billentyűleütést gyűjt.
- **Rootkit/backdoor:** tartós rejtett hozzáférést biztosít a támadónak.
- **Botnet malware:** kompromittált gépeket központi vezérlés alá von, például DDoS-hoz vagy spamhez.

Tipikus támadási technológiák:

- **Social engineering és phishing:** a felhasználó megtévesztése hitelesítő adatok vagy művelet kicsalására.
- **Brute force és credential stuffing:** jelszavak próbálgatása vagy kiszivárgott jelszavak újrafelhasználása.
- **DoS/DDoS:** a rendelkezésre állás támadása túlterheléssel.
- **Man-in-the-middle:** kommunikáció lehallgatása vagy módosítása két fél között.
- **Injection:** például SQL, command vagy script injection, ahol a támadó bemenetként kódot juttat a rendszerbe.
- **Privilege escalation:** alacsonyabb jogosultságból magasabb jogosultság megszerzése.
- **Exploit és sérülékenység-kihasználás:** szoftverhiba célzott kihasználása.

Hozzáférés-szabályozás alapjai

A hozzáférés-szabályozás célja annak eldöntése, hogy egy **alany** (felhasználó, folyamat, szolgáltatás) végrehajthat-e egy **műveletet** egy **objektumon** (fájl, adatbázis, API, szolgáltatás). A döntés alapja egy szabályrendszer, azaz **policy**.

Az AAA-modell:

- **Authentication – hitelesítés:** ki kezdeményezte a kérést?
- **Authorization – feljogosítás:** jogosult-e a kért műveletre?
- **Accounting – naplózás:** mi történt, mikor, milyen eredménnyel?

Hozzáférés-szabályozási komponensek:

- **PEP – Policy Enforcement Point:** kikényszeríti a döntést, például API gateway vagy operációs rendszer.
- **PDP – Policy Decision Point:** meghozza az engedélyezési döntést.
- **PIP – Policy Information Point:** attribútumokat szolgáltat, például szerepkör, eszközállapot, idő, hely.
- **Audit log:** a döntés és művelet nyoma.

Hozzáférés-szabályozási modellek

A hozzáférés-szabályozási modellek azt határozzák meg, milyen elv alapján születik meg az engedélyezési döntés. A választott modell mindig kompromisszum a rugalmasság, az adminisztrálhatóság és a biztonsági szigor között: egy kis csoportban elég lehet a DAC, nagyvállalati környezetben tipikus az RBAC, míg érzékeny vagy dinamikus rendszerekben gyakran ABAC vagy MAC szükséges. A legfontosabb általános elv a legkisebb jogosultság elve, vagyis az alany csak azt a hozzáférést kapja meg, amely a feladatához valóban szükséges. A modellek a gyakorlatban keveredhetnek is, például egy vállalati rendszer szerepköröket használ, de bizonyos műveleteket időhöz, eszközállapothoz vagy kockázati szinthez köt.

Modell	Lényege	Tipikus használat / megjegyzés
DAC	A tulajdonos dönt arról, ki férhet hozzá az objektumhoz.	Rugalmas, de könnyen túlengedélyezhető; klasszikus fájlrendszer-jogosultságok.
MAC	Központilag meghatározott címkék és biztonsági szintek alapján dönt.	Katonai/államigazgatási környezet; a tulajdonos nem írhatja felül.
RBAC	Jogosultságok szerepkörök-höz tartoznak, felhasználók szerepköröket kapnak.	Vállalati rendszerek; munkakör alapú jogosultságkezelés.
ABAC	Felhasználó-, erőforrás- és környezeti attribútumok alapján dönt.	Finomabb szabályok: idő, hely, eszközállapot, kockázati szint.
CBAC	A végrehajtott kód eredete, identitása, hash-e vagy aláírása alapján dönt.	Mobilkód, sandbox, futtatható állományok kontrollja.

Fontos kiegészítés: a szabályozás megvalósítható hozzáférési mátrixszal, ACL-lel vagy képességlistával. Az **ACL** objektumonként tárolja, ki mit tehet; a **capability** alanyonként tárolja, milyen objektumhoz milyen joga van.

Hozzáférés-szabályozás elosztott rendszerekben

Elosztott rendszerben a felhasználók, szolgáltatások és erőforrások több gépen, hálózati zónában vagy szervezetben lehetnek. Ezért a hozzáférési döntéshez szükséges identitást, attribútumokat, szabályokat és bizonyítékokat biztonságosan kell továbbítani.

Fő kihívások:

- **Bizalmi határok:** más szervezet vagy szolgáltatás állításait kell elfogadni.
- **Központi vs. lokális döntés:** központi policy könnyebben kezelhető, de kiesési pont lehet; lokális döntés skálázhatóbb, de inkonzisztens lehet.

- **Attribútumok frissessége:** szerepkör, jogosultság vagy token visszavonása gyorsan érvényesüljön.
- **Kommunikáció védelme:** titkosított, hitelesített csatorna szükséges.
- **Naplózás és audit:** több rendszer eseményeit kell időben és tartalmilag korrelálni.

Tipikus megoldások:

- **Kerberos:** jegyalapú, szimmetrikus kulcsos hitelesítés egy bizalmi tartományon belül.
- **SAML, OAuth2, OpenID Connect:** token/assertion alapú föderált identitás és hozzáférés webes és API-környezetben.
- **mTLS és tanúsítványok:** szolgáltatás-szolgáltatás kommunikáció kölcsönös hitelesítése.
- **Attribútum-alapú titkosítás:** az adat úgy titkosítható, hogy csak megfelelő attribútumokkal rendelkező kulcs birtokosa férjen hozzá.
- **Zero Trust szemlélet:** nincs automatikus bizalom belső hálózati pozíció alapján; minden hozzáférést hitelesíteni, autorizálni és naplózni kell.

Vizsgán mondható záró összefoglaló

Az 1-es tétel lényege, hogy az információbiztonság a bizalmasság, sértetlenség és rendelkezésre állás védelméből indul ki, de a modern rendszerekben hitelességre, elszámoltathatóságra és nyomonkövethetőségre is szükség van. A kiberbiztonság eszközei technikai, szervezeti és emberi kontrollokból állnak. A hozzáférés-szabályozás az AAA-modellre épül: először hitelesítünk, majd jogosultsági döntést hozunk, végül naplózunk. A DAC, MAC, RBAC, ABAC és CBAC különböző absztrakciós szinten szabályozza, ki, mit, milyen feltétellel tehet meg. Elosztott rendszerekben a fő probléma a bizalmi határok, a tokenek, attribútumok, policy-k és naplók konzisztens, biztonságos kezelése.

1.2.

Hitelesítés, felhasználó hitelesítés; Hitelesítés elosztott rendszerekben; Nyomonkövethetőség; Biztonságos üzemeltetés és incidenskezelés; Monitor Analyze Plan Execute-Knowledge (MAPE-K); Rendelet, szabványok.

1.3. Gépi tanulási alapismeretek

Felügyelt és nem felügyelt tanulás; egy- és többváltozós lineáris regresszió; gradiens csökkenési eljárás; sztochasztikus és mini-batch gradiens csökkentés; leírók normalizálása; polinomiális regresszió; normál egyenlet; logisztikus regresszió; két- és többosztályos osztályozás; regularizáció (alul- és túltanulás); regularizált lineáris és logisztikus regresszió; neurális hálók; backpropagation algoritmus; numerikus gradiensellenőrzés.

Felügyelt és nem felügyelt tanulás

Felügyelt tanulásnál a tanítóadatok címkézettek: adottak $(x^{(i)}, y^{(i)})$ párok. A cél olyan h_θ modell tanulása, amely új bemenetre jól becsli a kimenetet. Két alapfeladat:

- **Regresszió:** folytonos érték becslése, például lakásár vagy hőmérséklet.
- **Osztályozás:** diszkrét kategória becslése, például spam/nem spam vagy beteg/nem beteg.

Nem felügyelt tanulásnál nincs előre megadott címke. A cél az adatok belső szerkezetének feltárása, például klaszterezéssel, dimenziócsökkentéssel vagy anomáliadetektálással.

Lineáris regresszió

Az egyváltozós lineáris regresszió egyetlen bemeneti változóból becsül folytonos kimenetet:

$$\hat{y} = h_\theta(x) = \theta_0 + \theta_1 x.$$

Többváltozós esetben több jellemzőt használunk:

$$h_\theta(x) = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n = \theta^T x,$$

ahol $x_0 = 1$. A négyzetes hiba költségfüggvénye:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_\theta(x^{(i)}) - y^{(i)} \right)^2.$$

A modell tanításakor a költségfüggvény minimumát keressük. A gradiens megadja, merre nő leggyorsabban a hiba, ezért a paramétereket ennek ellenkező irányába frissítjük. Batch gradiens csökkenésnél minden iterációban a teljes tanítóhalmazon számoljuk a gradienst:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}.$$

Itt α a tanulási ráta; túl nagy értéknél a módszer divergálhat, túl kicsinél lassan konvergál.

Sztochasztikus és mini-batch gradiens csökkentés

Sztochasztikus gradiens csökkentésnél minden lépésben egyetlen tanítópélda alapján frissítünk:

$$\theta_j := \theta_j - \alpha \left(h_\theta(x^{(i)}) - y^{(i)} \right) x_j^{(i)}.$$

Előnye, hogy nagy adathalmaznál gyorsan ad haladási irányt; hátránya, hogy zajosabb, ezért a költségfüggvény nem feltétlenül csökken minden egyes lépésben.

Mini-batch gradiens csökkentésnél b darab példát használunk egy frissítéshez:

$$\theta_j := \theta_j - \alpha \frac{1}{b} \sum_{k=i}^{i+b-1} \left(h_\theta(x^{(k)}) - y^{(k)} \right) x_j^{(k)}.$$

Ez kompromisszum a batch és az SGD között, és modern hardveren jól párhuzamosítható.

Leírók normalizálása és polinomiális regresszió

A gradiens módszerek gyorsabban konvergálnak, ha a jellemzők hasonló skálán vannak. Gyakori normalizálás:

$$x_j^{(i)} := \frac{x_j^{(i)} - \mu_j}{s_j},$$

ahol μ_j a j -edik jellemző átlaga, s_j pedig szórása vagy terjedelme. Erre különösen akkor van szükség, ha például egyik jellemző néhány egység, a másik több ezres nagyságrendű.

Polinomiális regressziónál új jellemzőket képzünk a meglévőkből, hogy nemlineáris kapcsolatot is lineáris regressziós modellbe írassunk:

$$h_\theta(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3.$$

Ilyenkor a skálázás különösen fontos, mert x , x^2 és x^3 nagyságrendje nagyon eltérhet.

Normál egyenlet

Lineáris regressziónál az optimális paraméter iteráció nélkül is számítható:

$$\theta = (X^T X)^{-1} X^T y.$$

Előnye, hogy nem kell tanulási rátát választani és nincs iteratív konvergencia. Hátránya, hogy sok jellemző esetén a mátrixinverzió drága; ha $X^T X$ nem invertálható, pszeudoinverz használható.

Logisztikus regresszió

Bináris osztályozásnál $y \in \{0, 1\}$, ezért nem közvetlenül lineáris regressziót használunk, hanem valószínűséget becslünk:

$$h_\theta(x) = g(\theta^T x), \quad g(z) = \frac{1}{1 + e^{-z}}.$$

A sigmoid függvény bármely valós számot a $(0, 1)$ intervallumra képez le. Alapértelmezett döntési szabály:

$$h_{\theta}(x) \geq 0.5 \Rightarrow \hat{y} = 1, \quad h_{\theta}(x) < 0.5 \Rightarrow \hat{y} = 0.$$

Az összevont cross-entropy költségfüggvény:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right].$$

Ha $y = 1$, akkor a második tag kiesik; ha $y = 0$, akkor az első tag esik ki. A gradiens alakja formailag hasonló a lineáris regresszióéhoz:

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) x_j^{(i)}.$$

Két- és többosztályos osztályozás

Kétosztályos osztályozásnál egyetlen bináris döntést hozunk. Többosztályos esetben a **one-vs-all** módszer K osztályra K darab bináris osztályozót tanít:

$$h_{\theta}^{(k)}(x) = P(y = k \mid x; \theta), \quad k = 1, \dots, K.$$

Predikciókor azt az osztályt választjuk, amelyre a becült valószínűség legnagyobb:

$$\hat{y} = \arg \max_k h_{\theta}^{(k)}(x).$$

Neurális hálónál többosztályos osztályozásra gyakori a softmax kimenet.

Regularizáció

Alultanulás esetén a modell túl egyszerű, ezért a tanító- és validációs hiba is magas. Ez magas bias jelenség. **Túltanulás** esetén a modell túl jól illeszkedik a tanítóadat zajára, ezért a tanító hiba alacsony, de a validációs hiba magas. Ez magas variance jelenség.

A túltanulás kezelésének két tipikus módja a jellemzők számának csökkentése és a regularizáció. Regularizációval büntetjük a nagy paramétereket, így egyszerűbb, jobban általánosító modellt kapunk. A λ regularizációs paraméter szabályozza a büntetés erősségét: túl nagy értéknél alultanulás, túl kicsinél túltanulás maradhat.

Regularizált lineáris regressziónál:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

Regularizált logisztikus regressziónál:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2.$$

Fontos, hogy a bias tagot, vagyis θ_0 -t általában nem regularizáljuk.

Neurális hálók és backpropagation

A neurális hálók rétegelt struktúrájú modellek, amelyek nemlineáris összefüggések tanulására alkalmasak. Fő részeik:

- **Bemeneti réteg:** a jellemzőket fogadja.
- **Rejtett rétegek:** nemlineáris transzformációkat tanulnak; több rejtett réteg esetén mély neurális hálóról beszélünk.
- **Kimeneti réteg:** regressziós értéket, bináris kimenetet vagy osztályvalószínűségeket ad.

Egy neuron a bemenetek súlyozott összegét számítja ki, majd aktivációs függvényt alkalmaz:

$$z = w^T x + b, \quad a = \phi(z),$$

ahol ϕ lehet például sigmoid, tanh vagy ReLU. **Forward propagation** során a bemenetet rétegről rétegre előre felé számítjuk, amíg megkapjuk a predikciót.

Backpropagation során a veszteség gradiensét a kimeneti rétegtől visszafelé számítjuk a láncszabály segítségével. Egy egyszerű lokális derivált:

$$\frac{\partial L}{\partial w} = \frac{\partial L}{\partial a} \frac{\partial a}{\partial z} \frac{\partial z}{\partial w}.$$

A paraméterfrissítés például gradiens csökkenéssel:

$$w := w - \alpha \frac{\partial L}{\partial w}, \quad b := b - \alpha \frac{\partial L}{\partial b}.$$

Numerikus gradiensellenőrzés

A numerikus gradiensellenőrzés célja annak ellenőrzése, hogy a backpropagation implementáció helyesen számolja-e a gradienst. Egy paraméterre központi differenciával:

$$\frac{\partial J(\theta)}{\partial \theta_j} \approx \frac{J(\theta_1, \dots, \theta_j + \varepsilon, \dots) - J(\theta_1, \dots, \theta_j - \varepsilon, \dots)}{2\varepsilon}.$$

Ezt összehasonlítjuk a backpropagation által adott gradienssel. Ha a relatív eltérés kicsi, például 10^{-7} nagyságrendű, akkor az implementáció valószínűleg helyes:

$$\frac{\|g_{\text{num}} - g_{\text{backprop}}\|}{\|g_{\text{num}}\| + \|g_{\text{backprop}}\|} \ll 1.$$

Fontos, hogy a numerikus gradiensellenőrzés lassú, ezért csak hibakeresésre használjuk, tanítás közben nem.

Vizsgán mondható záró összefoglaló

A 3-as tétel a gépi tanulás alapvető tanítási és optimalizálási módszereiről szól. Felügyelt tanulásnál címkézett példákból tanulunk regressziós vagy osztályozási modellt, nem felügyelt tanulásnál pedig az adatok szerkezetét keressük. Lineáris regresszió-nál négyzetes hibát minimalizálunk, logisztikus regresszió-nál sigmoid kimenettel és

cross-entropy veszteséggel osztályozunk. A gradiens csökkenés batch, stochastic és mini-batch formában használható. A regularizáció a túltanulás csökkentésére bünteti a nagy paramétereket. A neurális hálók nemlineáris réteges modellek, amelyeket forward propagation és backpropagation segítségével tanítunk; a numerikus gradiens-ellenőrzés pedig a backpropagation képletek implementációját ellenőrzi.

2. Az adattudomány gyakorlati hátteréhez kapcsolódó alapismeretek.